

基于三阶段优化框架的单视图 3D 资产生成研究

Research on Single-View 3D Asset Generation Based on Three-Stage Optimization Framework

Team 1: Zhenyuan Hu, Yifu Wang, Sen Yang, Yizhou Zhang

2025年12月4日

摘要

摘要：随着生成式人工智能的发展，基于单张图像的 3D 建模已成为视觉生成领域的关键任务。然而，现有的主流方法（如 Hunyuan3D 等基于扩散模型的方案）在处理单视图输入时，常面临几何结构破碎、纹理跨视角不一致以及背面“幻觉”严重等问题。本项目并未止步于复现现有模型，而是提出了一种面向工程落地的**三阶段 3D 资产生成与优化框架**。该框架在基础生成之后，引入了专门设计的**几何修复网络 (Geometry Refinement Network, GRN)** 和**纹理一致性增强模块 (Texture Consistency Enhancement, TCE)**。实验结果表明，该方法在 Chamfer Distance 指标上降低了 34%，纹理一致性得分提升了 31%，证明了该模型级创新能显著提升单视图 3D 生成的鲁棒性与可用性。

关键词：单视图 3D 重建，扩散模型，几何修复，纹理一致性，三阶段优化

目录

1 引言 (Introduction)	2
1.1 背景与挑战	2
1.2 项目动机与目标	2
2 相关工作 (Related Work)	2
2.1 单视图 3D 重建	2
2.2 生成式 3D 模型	2
3 方法 (Methodology)	2
3.1 总体框架	3
3.2 阶段一：预处理与基础生成	3
3.3 阶段二：几何修复网络 (GRN)	3
3.4 阶段三：纹理一致性增强 (TCE)	3
4 实验 (Experiments)	4
4.1 实验设置	4
4.2 定量结果 (Quantitative Results)	4
4.3 消融实验 (Ablation Study)	4
4.4 定性分析 (Qualitative Analysis)	5
5 讨论与局限性 (Discussion)	5
6 结论与未来工作 (Conclusion)	5

1 引言 (Introduction)

1.1 背景与挑战

近年来，3D 内容生成（AIGC-3D）需求激增，广泛应用于游戏开发、VR/AR 以及工业设计。虽然基于 NeRF 和 3D Gaussian Splatting 的重建技术已取得进展，但它们通常依赖密集的多视图输入。在实际应用中，用户往往只能提供单张图像或简单的文本描述。

当前的 SOTA 方法（如 DreamFusion, Magic3D 以及本项目选用的基线 Hunyuan3D）试图解决单视图生成问题，但仍存在显著局限性：

1. **几何破碎与伪影：** 由于单视图信息缺失，模型推断的遮挡区域（如物体背面）常出现几何塌陷或空洞。
2. **纹理跨视角不一致：** 生成的纹理在不同视角下可能出现色彩突变或语义漂移（例如“Janus problem”，即多头问题）。
3. **不可用性：** 直接生成的 Mesh 网格往往拓扑结构混乱，无法直接用于工业渲染管线。

1.2 项目动机与目标

单纯依赖扩大模型规模（Scaling Law）来解决 3D 数据稀缺问题，在当前阶段成本极高且数据受限。我们认为，更现实的路径是将 2D 基础模型（Foundation Models）的强先验知识，通过工程化的模块迁移到 3D 生成中。

本项目不仅是对 Hunyuan3D 的复现，更旨在设计一个**模型级创新框架**，通过分阶段优化策略（Coarse-to-Fine），系统性地解决上述几何与纹理缺陷。

2 相关工作 (Related Work)

2.1 单视图 3D 重建

传统方法（Shape-from-Shading, Photometric Stereo）依赖强物理假设，难以处理复杂自然图像。基于深度学习的方法（如 Pixel2Mesh）通常需要特定类别的 3D 模板作为先验，泛化能力有限。

2.2 生成式 3D 模型

近期，基于扩散模型的方法（Text-to-3D）成为主流。

- **SDS (Score Distillation Sampling):** DreamFusion 首次提出 SDS 损失，利用 2D 扩散模型指导 3D 优化，但生成结果常过度平滑且纹理质量低。
- **Image-to-3D Pipelines:** 如 Zero-1-to-3, Wonder3D 等，通过微调扩散模型生成多视图图像，再进行重建。本项目选用的 **Hunyuan3D** 即属于此类，它在生成速度和质量上取得了平衡，但仍未完全解决几何一致性问题。

3 方法 (Methodology)

我们提出了一种模块化的**三阶段 3D 生成框架**，旨在逐级修复生成缺陷，而非依赖单一模型端到端解决所有问题。

3.1 总体框架

系统由三个核心阶段组成：

1. **阶段一：基础生成 (Base Generation)** —— 利用 Hunyuan3D 快速构建粗糙几何。
2. **阶段二：几何修复 (Geometry Refinement)** —— 引入 ****GRN**** 网络修复几何缺陷。
3. **阶段三：纹理一致化 (Texture Consistency)** —— 引入 ****TCE**** 模块优化纹理贴图。

3.2 阶段一：预处理与基础生成

预处理 (Pre-processing): 为了缓解单视图的信息匮乏，我们引入了多视图合成预投影 (Multi-View Synthetic Pre-Projection, MSPP)。

- 利用分割模型去除背景。
- 自动估计输入视角 (View Estimation) 。
- 使用 2D 扩散模型生成补充视角 (Side/Back views)，作为后续生成的引导条件。

随后，利用 Hunyuan3D 生成初始的粗糙 Mesh (M_0) 和粗糙纹理 (T_0)。此时的模型通常包含噪声和非流形结构。

3.3 阶段二：几何修复网络 (GRN)

这是本项目的核心模型创新之一。针对 M_0 中的孔洞和噪声，我们设计了一个轻量级的 3D 几何修复网络。

网络架构： GRN 基于轻量级 UNet 结构，参数量约为 0.8M - 1.3M。

- **输入 (5通道):** 深度图 (1) + 法线图 (3) + 掩膜 (1)。
- **网络层级:** Encoder-Decoder 结构，通道变化为 $32 \rightarrow 64 \rightarrow 128 \rightarrow 64 \rightarrow 32$ 。
- **输出 (4通道):** 修复后的深度 (1) + 修复后的法线 (3)。

损失函数： 为了保证几何光滑且保留结构细节，我们定义了如下损失函数：

$$L_{geo} = L_{rec} + \lambda_{sm} L_{smooth} + \lambda_{nc} L_{normal} \quad (1)$$

其中， L_{rec} 为 L1 重建损失， L_{smooth} 约束局部平滑度， L_{normal} 保证法线一致性。此外，对于网格优化，我们引入了拉普拉斯平滑项：

$$L_{lap} = ||\Delta v - \text{Lap}(\Delta v)||_2^2 \quad (2)$$

3.4 阶段三：纹理一致性增强 (TCE)

为了解决“多头问题”及纹理接缝，我们提出了 TCE 模块。

核心策略：

1. **CLIP 语义一致性：** 约束从任意视角渲染的图像 I_{render} 与文本提示 T_{prompt} 在 CLIP 特征空间的一致性。

$$L_{sem} = 1 - \text{sim}(\text{CLIP}(I_{render}), \text{CLIP}(T_{prompt})) \quad (3)$$

2. **Warp Consistency：** 利用光流法约束相邻视角的纹理像素对应关系，强迫纹理在空间上连续。
3. **显式稀疏优化：** 对生成的纹理贴图进行 Patch 级别的显式优化，而非仅依赖隐式扩散先验。

4 实验 (Experiments)

4.1 实验设置

- **数据集:** 包含 100 组不同类别的单视图输入（人物、物体、动物）。
- **基线 (Baseline):** 原始 Hunyuan3D 输出结果。
- **环境:** NVIDIA RTX 3090, PyTorch框架。
- **评价指标:**
 - **Chamfer Distance (CD) ↓:** 衡量几何结构的准确性。
 - **F1 Score ↑:** 衡量点云覆盖率与精度的调和平均。
 - **Consistency Score ↑:** 基于 CLIP 和光流计算的纹理一致性得分。

4.2 定量结果 (Quantitative Results)

表 1: 几何质量对比评估

Model	Chamfer Distance ↓	F1 Score ↑
Baseline (Hunyuan3D)	0.125	0.54
Baseline + GRN (Ours)	0.082	0.72

表 2: 纹理一致性评估

Model	Consistency Score ↑
Baseline	0.61
Baseline + TCE (Ours)	0.80

从表 1 可以看出，引入 GRN 后，Chamfer Distance 降低了约 34%，表明模型几何形状更接近真实结构（Ground Truth）。F1 分数的显著提升（+33%）说明修复后的模型在细节保留上更为完整。

4.3 消融实验 (Ablation Study)

为了验证各模块的有效性，我们进行了逐步叠加实验。

表 3: 综合消融实验

Configuration	Geometry Quality	Texture Quality	Overall Score
Baseline Only	Low	Low	Low
+ GRN	High	Low	Medium
+ TCE	Low	High	Medium
GRN + TCE (Full)	High	High	High

分析:

- 仅使用 GRN 时，几何结构得到修复，但纹理模糊问题依然存在。
- 仅使用 TCE 时，纹理变得清晰且一致，但若几何底板破碎，纹理会出现错误投影。
- 两者结合（Full Model）实现了互补，达到了最佳的视觉与几何效果。

4.4 定性分析 (Qualitative Analysis)

我们观察到，在输入信息严重缺失的情况下（如极度遮挡的背面），GRN 利用其学习到的几何先验成功补全了形状，避免了常见的“凹陷”现象。同时，TCE 有效消除了多视角下的颜色跳变，使生成的 3D 资产在 360 度旋转展示时更加自然。

5 讨论与局限性 (Discussion)

为什么 GRN 有效？ GRN 实际上充当了一个 3D 去噪自编码器。它并未凭空“创造”信息，而是利用大量 3D 数据训练出的先验知识，去识别并修正那些不符合物理规律的几何拓扑（如非流形边、尖锐噪声）。

局限性： 目前 GRN 的训练依赖于特定类别的合成数据，对于极其抽象或艺术化的输入，其修复可能会导致过度平滑，丢失原本的风格化特征。此外，推理时间相较于端到端模型增加了约 15%。

6 结论与未来工作 (Conclusion)

本项目提出并验证了一个基于 Hunyuan3D 的**三阶段 3D 资产生成与优化框架**。通过引入**几何修复网络 (GRN)** 和 **纹理一致性增强 (TCE)** 两个模型级创新模块，我们成功解决了单视图生成中常见的几何破碎与纹理不一致问题。

定量实验显示，该方法在几何准确性和纹理质量上均优于原始基线。这证明了将 2D 基础模型的生成能力与专门设计的 3D 优化模块相结合，是一条极具工程落地价值的技术路径。

未来工作： 我们计划探索 **Hybrid Mesh-Gaussian** 表示法，结合 Mesh 的明确几何结构与 3D Gaussian Splatting 的高效渲染优势，进一步提升复杂场景下的生成质量。